

Заболевания сердечно-сосудистой системы являются самой распространённой причиной смерти во всём мире [1], в России за последние 30 лет доля смертей от болезней системы кровообращения составляла от 44 до 57 процентов [2]. Очевидна необходимость внедрения новых методов диагностики и предупреждения заболеваний этого класса.

На данный момент ЭКГ (электрокардиограмма) является одним из основных средств диагностирования заболеваний сердца. Сама процедура проведения электрокардиографии [3] не требует от работника высокой квалификации, в отличие от анализа результатов – это может делать только врач. Сейчас во многих направлениях медицины разрабатываются способы автоматического распознавания потенциальных больных для их последующего направления к реальному врачу с целью снятия нагрузки со специалистов. Электрокардиография, конечно, не исключение.

В работе будет рассмотрена задача многоклассовой классификации заболеваний по данным ЭКГ с использованием нейронных сетей [4]. При этом исследованы различные архитектуры, которые реализуют общепринятые подходы, такие как свёрточные [5] и рекуррентные [6–10] сети. Лучшие из них будут взяты за основу конечной модели.

Примеры ЭКГ можно найти в [11].

- [1] Ritchie, Hannah. Causes of death. <https://ourworldindata.org/causes-of-death>.
- [2] Число умерших по основным классам и отдельным причинам смерти за год. <https://www.fedstat.ru/indicator/31620>.
- [3] Strauss, Galen S Wagner; David G. Marriott's practical electrocardiography. / Galen S Wagner; David G Strauss. — Philadelphia: Wolters Kluwer Health/Lippincott Williams & Wilkins, 2014.
- [4] Haykin, S. Neural Networks: A Comprehensive Foundation / S. Haykin, S.S. Haykin, S.A. HAYKIN. International edition. — Prentice Hall, 1999. <https://books.google.ru/books?id=bX4pAQAAAMAJ>.
- [5] Convolutional neural networks: an overview and application in radiology / Rikiya Yamashita, Mizuho Nishio, Richard K. G. Do, Kaori Togashi // Insights into Imaging. — 2018. — Vol. 9. — Pp. 611 – 629.
- [6] Abdulwahab, Saddam. Deep Learning Models for Paraphrases Identification: Ph.D. thesis. — 2017. — 09.
- [7] Cho, Kyunghyun. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. — 2014.
- [8] Hochreiter, Sepp. Long Short-term Memory / Sepp Hochreiter, Jurgen Schmidhuber // Neural computation. — 1997. — 12. — Vol. 9. — Pp. 1735–80.
- [9] Olah, Christopher. Understanding LSTM Networks. — 2015. <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>.
- [10] Chung, Junyoung. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling. — 2014.
- [11] Jenkins, Dr Dean. ECG Library. <https://ecglibrary.com/ecghome.php>.

В последние годы выходит довольно много статей по классификации временных рядов. В них приводятся сравнения разных моделей, а также результаты экспериментов с новыми моделями, которые зачастую тестируются на данных UEA & UCR Time Series Classification Repository [15] (далее - UCR/UEA). Например, в статье [16] исследователи получили, что ResNet [17] превосходит другие модели на большинстве датасетов (наборов данных), однако для классификации ЭКГ лучше себя показал FCN [18]. Также интересны статьи про модели BOSS [19] (Bag-of-SFA-Symbols) и семейство COTE [20–22] (Collective of Transformation-based Ensembles). Они упомянуты на сайте архива UCR/UEA как демонстрирующие наибольшую точностью для датасетов ECG200 и ECG5000. Однако это модели, не относящиеся к нейронным сетям.

Ещё одна предложенная архитектура – LSTM-FCN [23] (Long Short Term Memory Fully Convolutional Network) – показывает хорошие результаты на множестве различных датасетов. Хотя в приведённых результатах эта модель уступает на единственном представленном датасете с ЭКГ.

[15] Anthony Bagnall Jason Lines, William Vickers. The UEA & UCR Time Series Classification Repository.

<http://timeseriesclassification.com/dataset.php>.

[16] Deep learning for time series classification: a review / Hassan Ismail Fawaz, Germain Forestier, Jonathan Weber et al. — 2018.

[17] He, Kaiming. Deep Residual Learning for Image Recognition. — 2015.

[18] Wang, Zhiguang. Time Series Classification from Scratch with Deep Neural Networks: A Strong Baseline. — 2016.

[19] Schafer, Patrick. The BOSS is concerned with time series classification in the presence of noise / Patrick Sch · afer // Data Mining and Knowledge Discovery. — 2015. — 11. — Vol. 29.

[20] Time-Series Classification with COTE: The Collective of Transformation-Based Ensembles / Anthony Bagnall, Jason Lines, Jon Hills, Aaron Bostrom // IEEE Transactions on Knowledge and Data

Engineering. — 2015. Vol. 27.

[21] Bagnall, Anthony. A tale of two toolkits, report the third: on the usage and performance of HIVE-COTE v1.0. — 2020.

[22] Middlehurst, Matthew. HIVE-COTE 2.0: a new meta ensemble for time series classification. — 2021.

[23] Multivariate LSTM-FCNs for Time Series Classification / Fazle Karim, Somshubra Majumdar, Houshang Darabi, Samuel Harford. — 2018.

Наборы данных.

9 датасетов из архива UCR/UEA. Два из них многоканальные, остальные – одноканальные. Данный набор датасетов очень удобен в использовании по сравнению с другими, потому что данные в нём одинаковой длины, хранятся в едином формате, который легко прочитать из файлов. Также, в этих датасетах явно прописаны классы, соответствующие каждому объекту данных.

Эти 9 датасетов полезны в разной степени. Только три из них разбиты по классам именно по заболеваниям – это ECG200, ECG5000 и AtrialFibrillation. Также обратим внимание на датасеты с самой большой тестовой выборкой – это ECG5000 и два датасета NonInvasiveFetalECGThorax. Это позволяет иметь большую уверенность в устойчивости получаемых результатов.

У этих же датасетов к тому же самые большие обучающие выборки. Ниже представлена сводная таблица 2 с краткой информацией по каждому датасету. А в таблице 3 указаны принципы разбинок на классы.

Таблица 2: Параметры использованных датасетов

| датасет | размер обучающей выборки | размер тестовой выборки | число каналов | длина ряда | количество классов |
|----------------------------|--------------------------|-------------------------|---------------|------------|--------------------|
| CinCECGTorso | 40 | 1380 | 1 | 1639 | 4 |
| ECG200 | 100 | 100 | 1 | 96 | 2 |
| ECG5000 | 500 | 4500 | 1 | 140 | 5 |
| ECGFiveDays | 23 | 861 | 1 | 136 | 2 |
| NonInvasiveFetalECGThorax1 | 1800 | 1965 | 1 | 750 | 42 |
| NonInvasiveFetalECGThorax2 | 1800 | 1965 | 1 | 750 | 42 |
| TwoLeadECG | 23 | 1139 | 1 | 82 | 2 |
| AtrialFibrillation | 15 | 15 | 2 | 640 | 3 |
| StandWalkJump | 12 | 15 | 4 | 2500 | 3 |

Таблица 3: Разбивка датасетов на классы

| датасет | классы |
|--------------------|---|
| CinCECGTorso | 4 разных человека |
| ECG200 | нормальное сердечное сокращение и сокращение при инфаркте миокарда |
| ECG5000 | нормальное сердечное сокращение, преждевременное сокращение желудочков "R на T" вида, преждевременное сокращение желудочков, суправентрикулярное преждевременное сокращение и неклассифицированное сокращение |
| ECGFiveDays | 2 различные даты, в которые проводились измерения у одного пациента |
| TwoLeadECG | 2 разных отведения |
| AtrialFibrillation | мерцательная аритмия, которая (1) не заканчивается минимум час после измерений, (2) не заканчивается минимум минуту после измерений, (3) заканчивается в течение секунды после измерений |
| StandWalkJump | разные активности человека - стоит, бежит, прыгает |

Реализации сетей для первоначального анализа можно взять с нескольких источников, они указаны в таблице 4

Таблица 4: Источники сетей

| hfawaz | lxdv | Luc Nies | tsai | | |
|---------------|-------------|----------|-------------------|------------------|------------------|
| fcn_dl4tsc | EcgResNet34 | lstms | FCN | ResCNN | TSTPlus |
| mlp_dl4tsc | ZolotyhNet | | FCNPlus | ResNet | XceptionTime |
| resnet_dl4tsc | HeartNet1D | | TCN | ResNetPlus | XceptionTimePlus |
| tlenet | HeartNet2D | | InceptionTime | RNN | XCM |
| encoder | | | InceptionTimePlus | RNNPlus | XCMPlus |
| medcnn | | | MLP | RNN_FCN | XResNet1d |
| cnn | | | gMLP | RNN_FCNPlus | XResNet1dPlus |
| inception | | | mWDN | TransformerModel | TSPerceiver |
| | | | OmniScaleCNN | TST | TSiTPlus |

1) hfawaz – псевдоним пользователя GitHub. Можно использовать его код, сопровождавший исследование по временным рядам [35]. Интересны архитектуры модели и некоторые элементы сбора статистики.

2) lxdw – также псевдоним на GitHub. Представленный в [32] код является частью магистерской выпускной квалификационной работы по свёрточным сетям применительно к ЭКГ.

3) Luc Nies в [33] реализовал простую рекуррентную сеть, предназначенную для другого датасета ЭКГ.

4) tsai – крупный репозиторий [34], в котором реализовано множество современных моделей для классификации временных рядов. Эти модели кажутся самыми удобными в использовании на практике, встраивание их в проект кажется наиболее простым.

[32] А.Ю., Ляшук. ECG Arrhythmia classification.

<https://github.com/lxdv/ecg-classification>.

[33] Nies, Luc. Using LSTMs to classify ECG signals in several different heart diseases.

<https://github.com/LucNies/ecg-classification>.

[34] Oguiza, Ignacio. tsai - A state-of-the-art deep learning library for time series and sequential data. — Github. — 2022.

<https://github.com/timeseriesAI/tsai>.

[35] Deep learning for time series classification: a review / Hassan Ismail Fawaz, Germain Forestier, Jonathan Weber et al. // Data Mining and Knowledge Discovery. — 2019. — Vol. 33, no. 4. — Pp. 917–963.

Задача.

1. Запустить уже имеющиеся архитектуры на доступных наборах данных. Для анализа точности классификации использовать метрики Accuracy и F_2 .
2. Выбрать лучшие подходы и попробовать изменить архитектуру некоторых сетей для улучшения метрик:
 - а) удаление, изменение отдельных слоев
 - б) изменение способа нормализации
 - в) добавить новые слои
 - г) Ещё один способ улучшить результаты – объединить несколько моделей в одну (в ансамбль).